

Authorship Classification

Seminarski rad u okviru kursa
Istraživanje podataka 2
Matematički fakultet

Zagorka Pantović
mi20227@alas.matf.bg.ac.rs

15. jul 2026.

Sažetak

U ovom radu analiziran je problem identifikacije autora teksta korišćenjem metoda mašinskog učenja (eng. *machine learning*). Cilj istraživanja je razvoj modela koji na osnovu teksta novinskog članka može da predvidi njegovog autora.

Korišćen je skup podataka Reuter_50_50 koji sadrži 5000 novinskih članaka napisanih od strane 50 različitih autora. Rad obuhvata kompletnu analitičku proceduru koja uključuje analizu podataka, obradu teksta, ekstrakciju atributa pomoću TF-IDF metode, kao i treniranje i evaluaciju više klasifikacionih algoritama.

Testirano je pet različitih modela mašinskog učenja: Multinomial Naive Bayes, Logistic Regression, Linear Support Vector Machine, K-Nearest Neighbors i Random Forest. Rezultati pokazuju da Linear SVM postiže najbolje performanse sa tačnošću klasifikacije od približno 67%.

Eksperimenti su takođe pokazali da redukcija broja atributa sa 5000 na 3000 ima minimalan uticaj na performanse modela, dok dalje smanjenje na 1000 atributa dovodi do primetnog pada tačnosti.

Sadržaj

1	Uvod	3
2	Opis skupa podataka	3
3	Analiza tekstualnih dokumenata	4
4	Obrada teksta	4
4.1	Osnovna obrada teksta	4
4.2	Napredna obrada teksta	4
5	Transformacija teksta u numeričke attribute	5
6	Redukcija dimenzionalnosti	5
7	Klasifikacioni modeli	6
7.1	Multinomial Naive Bayes	6
7.2	Logistic Regression	6
7.3	Support Vector Machine	7

7.4	K-Nearest Neighbors	7
7.5	Random Forest	7
8	Eksperimentalni rezultati	8
9	Zaključak	9

1 Uvod

Automatska analiza teksta predstavlja važnu oblast u okviru obrade prirodnog jezika (eng. *Natural Language Processing - NLP*). Jedan od zanimljivih problema u ovoj oblasti je identifikacija autora teksta, poznata kao *authorship attribution*. Ovaj problem podrazumeva određivanje autora teksta na osnovu stilskih karakteristika i izbora reči koje se pojavljuju u tekstu.

Primene ovakvih metoda mogu se pronaći u različitim oblastima, uključujući digitalnu forenziku, analizu plagijata, identifikaciju anonimnih autora i analizu stilskih obrazaca u književnosti.

Razvoj metoda mašinskog učenja omogućio je automatsku analizu velikih kolekcija tekstualnih dokumenata. Algoritmi mašinskog učenja mogu da identifikuju obrasce u tekstu koji su karakteristični za određene autore, čak i kada su razlike između autora relativno suptilne.

U ovom radu analiziran je skup podataka koji sadrži novinske članke agencije Reuters. Cilj istraživanja je da se ispita koliko uspešno različiti klasifikacioni algoritmi mogu da identifikuju autora teksta na osnovu sadržaja članka.

Rad obuhvata kompletan proces analize podataka koji uključuje:

- analizu i istraživanje skupa podataka,
- obradu i čišćenje teksta,
- transformaciju teksta u numeričke reprezentacije,
- treniranje i poređenje više klasifikacionih modela.

Rezultati eksperimenata omogućavaju uvid u performanse različitih algoritama mašinskog učenja u zadatku klasifikacije autora.

2 Opis skupa podataka

Za potrebe ovog istraživanja korišćen je skup podataka *Reuter_50_50*. Ovaj skup podataka predstavlja kolekciju novinskih članaka koje su napisali novinari agencije Reuters.

Skup podataka sadrži ukupno 5000 tekstualnih dokumenata raspoređenih među 50 autora. Svaki autor zastupljen je sa tačno 100 članaka, što znači da je skup podataka potpuno izbalansiran.

Dokumenti su podeljeni u dva podskupa:

- trening skup (2500 dokumenata)
- test skup (2500 dokumenata)

Ovakva podela omogućava objektivnu evaluaciju modela, jer se modeli treniraju na jednom delu podataka, a testiraju na drugom koji nije korišćen tokom treniranja.

Svaki dokument predstavlja novinski članak koji pokriva različite teme kao što su ekonomija, finansije, međunarodna trgovina i tehnologija. Zbog toga tekstovi sadrže veliki broj specifičnih termina, naziva kompanija i geografskih lokacija.

Iz grafika se vidi da je skup podataka ravnomerno raspoređen, odnosno svaki autor ima isti broj dokumenata.

Ovakva struktura skupa podataka je pogodna za eksperimente u klasifikaciji jer eliminiše problem neuravnoteženih klasa.

3 Analiza tekstualnih dokumenata

Pre primene algoritama mašinskog učenja izvršena je eksploratorna analiza podataka (eng. *Exploratory Data Analysis - EDA*). Cilj ove analize bio je da se ispita struktura tekstova i identifikuju osnovne karakteristike skupa podataka.

Jedna od analiziranih karakteristika bila je dužina dokumenata. Dužina teksta merena je brojem karaktera i brojem reči u dokumentu.

Rezultati pokazuju da prosečan dokument sadrži približno 500 reči. Većina tekstova nalazi se u rasponu između 400 i 600 reči, dok se samo manji broj dokumenata značajno razlikuje od ove vrednosti.

Takođe je analizirana učestalost pojavljivanja reči u celom skupu podataka.

Najčešće reči u skupu podataka su funkcionalne reči kao što su *the*, *to*, *of* i *and*. Ove reči se nazivaju *stopwords* i obično ne nose značajnu semantičku informaciju. Zbog toga se u kasnijim fazama obrade često uklanjaju iz teksta.

4 Obrada teksta

Pre primene algoritama mašinskog učenja neophodno je izvršiti obradu tekstualnih podataka. Tekstualni podaci u svom originalnom obliku sadrže različite elemente koji mogu negativno uticati na performanse modela, kao što su interpunkcija, brojevi i veoma česte reči koje nemaju veliku semantičku vrednost.

Proces obrade teksta (eng. *text preprocessing*) obuhvata nekoliko koraka koji omogućavaju transformaciju sirovog teksta u pogodniji oblik za dalju analizu.

U ovom radu implementirane su dve različite strategije obrade teksta:

- osnovna obrada teksta
- napredna obrada teksta

4.1 Osnovna obrada teksta

Osnovna obrada teksta obuhvata sledeće korake:

- konverziju svih karaktera u mala slova
- uklanjanje interpunkcije
- uklanjanje numeričkih karaktera
- uklanjanje suvišnih razmaka

Cilj ove transformacije je standardizacija teksta kako bi se izbegle razlike koje nastaju zbog različitog zapisa istih reči.

4.2 Napredna obrada teksta

Napredna obrada teksta uključuje dodatne korake koji imaju za cilj da uklone neinformativne elemente iz teksta.

U ovoj fazi primenjeni su sledeći postupci:

- uklanjanje stop reči (eng. *stopwords*)
- lematizacija reči (eng. *lemmatization*)

Stop reči su veoma česte reči u jeziku kao što su *the*, *and*, *to* i *of*. Ove reči se pojavljuju u gotovo svim tekstovima i obično ne doprinose razlikovanju dokumenata.

Lematizacija predstavlja proces svodjenja reči na njihov osnovni oblik. Na primer, reči *running*, *runs* i *ran* mogu se svesti na osnovni oblik *run*.

Primena ovih tehnika omogućava smanjenje dimenzionalnosti skupa podataka i istovremeno zadržavanje najvažnijih informacija sadržanih u tekstu.

Analiza je pokazala da prosečan broj reči po dokumentu opada sa približno 506 na oko 302 nakon primene napredne obrade teksta. To znači da je uklonjeno oko 40% reči koje se smatraju manje informativnim.

5 Transformacija teksta u numeričke atribute

Algoritmi mašinskog učenja ne mogu direktno da rade sa tekstualnim podacima. Zbog toga je neophodno transformisati tekst u numeričku reprezentaciju.

Jedna od najčešće korišćenih metoda za ovu transformaciju je TF-IDF (eng. *Term Frequency - Inverse Document Frequency*).

TF-IDF metoda meri značaj svake reči u dokumentu u odnosu na ceo skup dokumenata. Osnovna ideja ove metode je da reči koje se često pojavljuju u određenom dokumentu, ali retko u ostalim dokumentima, nose veću informativnu vrednost.

TF komponenta (eng. *term frequency*) predstavlja učestalost pojavljivanja reči u dokumentu, dok IDF komponenta (eng. *inverse document frequency*) smanjuje značaj reči koje se pojavljuju u velikom broju dokumenata.

Matematički izraz za TF-IDF može se predstaviti kao:

$$TFIDF(t, d) = TF(t, d) \times IDF(t)$$

gde je:

- $TF(t, d)$ — učestalost termina t u dokumentu d
- $IDF(t)$ — mera retkosti termina u celom skupu dokumenata

U ovom radu korišćen je TF-IDF vektorizator koji generiše maksimalno 5000 atributa, odnosno najinformativnijih reči u skupu podataka.

Rezultat ove transformacije je matrica dimenzija:

- 2500 dokumenata u trening skupu
- 2500 dokumenata u test skupu
- 5000 atributa koji predstavljaju različite reči

Ovakva reprezentacija omogućava primenu različitih klasifikacionih algoritama nad tekstualnim podacima.

6 Redukcija dimenzionalnosti

Tekstualni skupovi podataka često sadrže veoma veliki broj atributa. Velika dimenzionalnost može dovesti do povećane složenosti modela i sporijeg treniranja algoritama.

Zbog toga je u ovom radu primenjena metoda selekcije atributa zasnovana na hi-kvadrat statistici (eng. *Chi-Square feature selection*).

Hi-kvadrat test meri zavisnost između pojavljivanja određene reči i pripadnosti određenoj klasi (autoru). Reči koje imaju jaču statističku povezanost sa određenim autorima dobijaju veće vrednosti hi-kvadrat statistike.

Na osnovu ove metode generisana su dva redukovana skupa atributa:

- skup od 3000 najinformativnijih atributa
- skup od 1000 najinformativnijih atributa

Ova redukcija omogućava analizu uticaja broja atributa na performanse modela mašinskog učenja.

Eksperimenti su pokazali da smanjenje broja atributa sa 5000 na 3000 ima veoma mali uticaj na tačnost modela, dok dalja redukcija na 1000 atributa dovodi do primetnog pada performansi.

7 Klasifikacioni modeli

U cilju rešavanja problema klasifikacije autora primenjeni su različiti algoritmi mašinskog učenja. Izabrani su algoritmi koji se često koriste u zadacima klasifikacije tekstualnih podataka.

U okviru ovog rada testirano je pet različitih modela:

- Multinomial Naive Bayes
- Logistic Regression
- Linear Support Vector Machine
- K-Nearest Neighbors
- Random Forest

Svi modeli trenirani su nad TF-IDF reprezentacijom dokumenata, a performanse su evaluirane na test skupu podataka.

7.1 Multinomial Naive Bayes

Naive Bayes predstavlja probabilistički klasifikacioni algoritam zasnovan na Bajesovoj teoremi. Osnovna pretpostavka ovog modela je nezavisnost atributa.

Multinomial varijanta Naive Bayes algoritma posebno je pogodna za tekstualne podatke jer koristi frekvenciju pojavljivanja reči u dokumentima.

Zbog svoje jednostavnosti i brzine treniranja, ovaj algoritam se često koristi kao početna referentna metoda u zadacima klasifikacije teksta.

7.2 Logistic Regression

Logistička regresija (eng. *Logistic Regression*) predstavlja linearni klasifikacioni model koji procenjuje verovatnoću pripadnosti određenoj klasi.

U slučaju višeklasne klasifikacije koristi se strategija *one-vs-rest*, gde se za svaku klasu trenira poseban klasifikator.

Ovaj model se često koristi u problemima klasifikacije teksta zbog dobre interpretabilnosti i relativno stabilnih performansi.

7.3 Support Vector Machine

Support Vector Machine (SVM) predstavlja jedan od najefikasnijih algoritama za klasifikaciju tekstualnih podataka.

SVM algoritam pokušava da pronađe hiperravan koja maksimalno razdvaja različite klase u prostoru atributa.

U ovom radu korišćena je linearna varijanta ovog algoritma (Linear SVM), koja je posebno pogodna za visoko-dimenzionalne podatke kakvi se javljaju u TF-IDF reprezentaciji teksta.

7.4 K-Nearest Neighbors

K-Nearest Neighbors (KNN) predstavlja jednostavan algoritam zasnovan na principu sličnosti između dokumenata.

Klasifikacija novog dokumenta vrši se na osnovu najbližih suseda u prostoru atributa.

Iako je ovaj algoritam intuitivan i jednostavan za implementaciju, njegova efikasnost može opasti u prostorima visoke dimenzionalnosti zbog takozvanog problema *curse of dimensionality*.

7.5 Random Forest

Random Forest predstavlja ansambl metod zasnovan na velikom broju stabala odlučivanja (eng. *decision trees*).

Svako stablo trenira se na nasumičnom podskupu podataka i atributa, a konačna odluka donosi se glasanjem svih stabala.

Prednost ovog algoritma je sposobnost modelovanja složenih nelinearnih odnosa između atributa.

8 Eksperimentalni rezultati

Eksperimenti su sprovedeni nad tri različita skupa atributa:

- 5000 atributa (pun TF-IDF skup)
- 3000 atributa (redukovani skup)
- 1000 atributa (redukovani skup)

Performanse modela merene su pomoću sledećih metrika:

- tačnost klasifikacije (accuracy)
- preciznost (precision)
- odziv (recall)
- F1 mera

Posebna pažnja posvećena je makro proseku (eng. *macro average*), jer skup podataka sadrži veliki broj klasa.

Tabela 1: Poređenje performansi klasifikacionih modela

Model	5000 atributa	3000 atributa	1000 atributa
Linear SVM	0.671	0.658	0.612
Random Forest	0.647	0.664	0.628
Logistic Regression	0.636	0.629	0.588
Multinomial NB	0.627	0.612	0.588
KNN	0.551	0.542	0.464


Rezultati prikazani u tabeli 1 pokazuju da Linear SVM postiže najbolje performanse kada se koristi kompletan skup atributa.

Sa druge strane, Random Forest postiže najbolje rezultate kada se koristi redukovani skup od 3000 atributa.

Na slici 1 prikazano je poređenje performansi različitih modela u odnosu na broj atributa koji se koristi u modelu.

Može se primetiti da smanjenje broja atributa sa 5000 na 3000 ima relativno mali uticaj na performanse većine modela.

Međutim, dodatno smanjenje broja atributa na 1000 dovodi do primetnog pada performansi kod gotovo svih algoritama.



Slika 1: Poređenje performansi klasifikacionih modela

9 Zaključak

U ovom radu analiziran je problem klasifikacije autora teksta korišćenjem metoda mašinskog učenja.

Eksperimenti su sprovedeni nad skupom podataka Reuter_50_50 koji sadrži 5000 novinskih članaka raspoređenih među 50 autora.

Proces analize obuhvatio je nekoliko faza, uključujući obradu teksta, transformaciju podataka pomoću TF-IDF metode, selekciju atributa i treniranje više klasifikacionih modela.

Rezultati eksperimenata pokazali su da Linear SVM postiže najbolje performanse kada se koristi kompletan skup atributa.

Takođe je pokazano da redukcija broja atributa sa 5000 na 3000 ima minimalan uticaj na tačnost modela, što ukazuje da je moguće značajno smanjiti dimenzionalnost podataka bez velikog gubitka informacija.

Dalja redukcija na 1000 atributa dovodi do primetnog pada performansi, što ukazuje da je određen broj atributa neophodan kako bi se zadržale važne informacije o stilu pisanja autora.

Rezultati ovog istraživanja potvrđuju da metode mašinskog učenja mogu uspešno da identifikuju autore tekstova na osnovu njihovih stilskih karakteristika.